08

AULA 08 · Terça, 25/08

Data Lake

Big Data e arquiteturas de dados modernas

Módulo · Arquitetura de Serviços e Dados

Prof.: Everton J Benedicto

ada

Cronograma das Aulas

01
Seg 10/08
Introdução ao Módulo e Docker

02
Qua 12/08
Arquitetura de Servidores

03
Sex 14/08
Apache e Nginx

04
Seg 17/08
Proxy Reverso e DNS

05
Qua 19/08
CI/CD e Ciclo de Vida

06
Sex 21/08
Cloud Computing

07
Seg 24/08
Arquitetura de Dados e Data Warehouse

08
Ter 25/08
Data Lake

09
Sex 28/08
Concluir atividades e preencher rubricas

COMBINADO DA TURMA

Por favor!

Bora participar!



Câmera ligada + mão levantada
= aula top!

INTERVALO · 16:30 BRT

Combinados da nossa aula

1. Câmeras ligadas.
2. Entrem no horário: início e intervalo.
3. Participem da aula.
4. Tirem dúvidas.
5. Levantem a mão para tirar dúvidas.

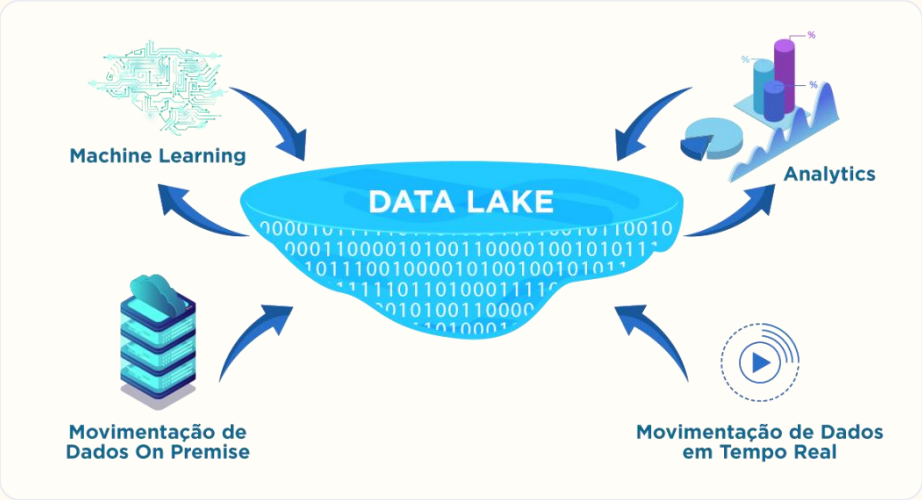
REVIEW!

Recapitulando a Aula 7

- ✓ Arquitetura de Dados organiza armazenamento, processamento, disponibilização e visualização.
- ✓ Data Warehouse: repositório central OLAP para análises e decisões.
- ✓ ETL: Extrair → Transformar → Carregar.
- ✓ Data Marts são visões especializadas do DW para cada área de negócio.

CONCEITO

O que é um Data Lake?

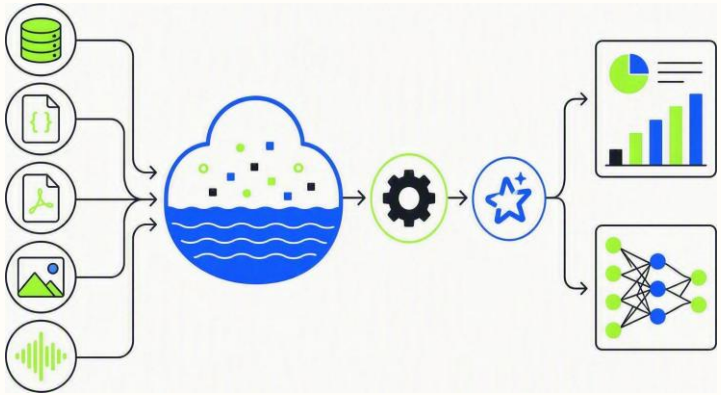


1. **Armazena tudo:** dados estruturados, semi e não estruturados
2. **Schema-on-read:** o esquema é definido na leitura
3. **Escala petabytes:** logs, imagens, vídeos, JSON, CSV...
4. **Habilita ML:** análise exploratória e descoberta de dados

Fonte: solvimm.com

NA PRÁTICA

Como funciona um Data Lake na prática

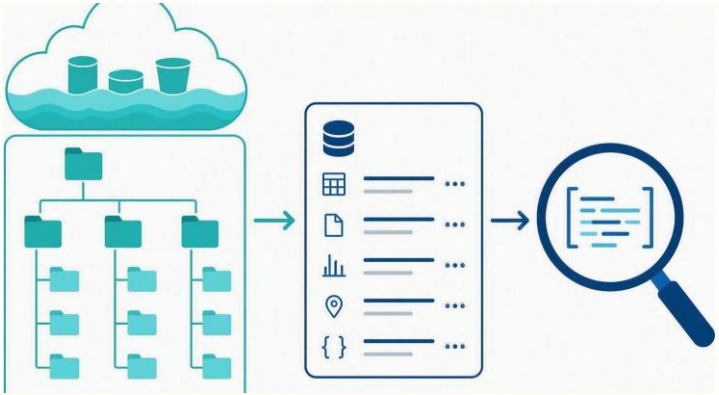


1. **Ingestão:** coleta em tempo real ou em lotes, de dados estruturados, semi e não estruturados
2. **Armazenamento:** barato e escalável na nuvem (S3, GCS, Azure Data Lake), sem alterar a origem
3. **Processamento:** Spark, Databricks e motores SQL tratam, filtram e transformam os dados
4. **Consumo:** relatórios de BI, modelos de Machine Learning e IA

Fluxo: Ingestão → Armazenamento → Processamento → Consumo

POR BAIXO DOS PANOS

Como gravamos e recuperamos dados no Data Lake



1. **Gravação:** os dados entram como arquivos (CSV, Parquet, JSON) em um sistema de arquivos na nuvem (S3, Azure Blob)
2. **Organização em pastas:** o particionamento cria caminhos lógicos, como /financas/faturamento/2026/08/
3. **Catálogo de dados:** AWS Glue ou Hive Metastore é o índice: guarda o caminho da tabela e suas colunas
4. **Consulta:** Athena, Spark, Presto ou Databricks leem o índice, vão à pasta certa e aplicam schema-on-read

SELECT valor, data FROM financas_faturamento WHERE data >= '2026-01-01';

COMPARAÇÃO

Data Warehouse vs Data Lake

Data Warehouse

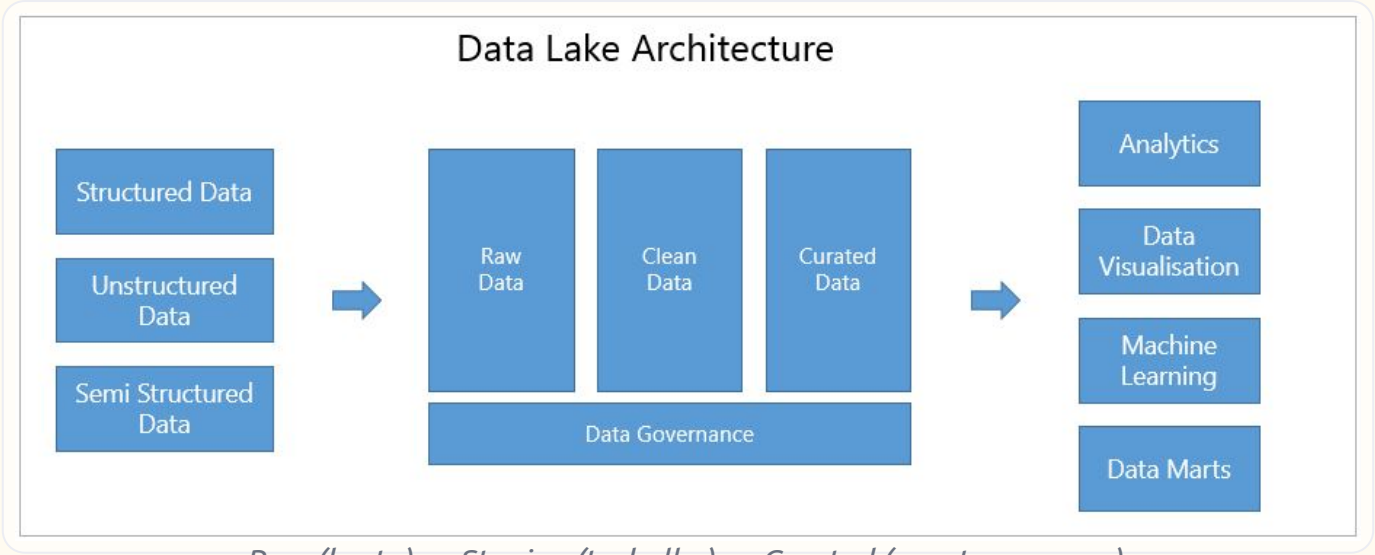
- Dados relacionais estruturados
- Schema-on-write (antes de gravar)
- Alta qualidade, já tratados
- Analistas de negócio, BI

Data Lake

- Todos os tipos de dados
- Schema-on-read (na leitura)
- Dados brutos, maior variedade
- Cientistas de dados, ML

ARQUITETURA

Arquitetura em Camadas do Data Lake



Raw (bruto) → Staging (trabalho) → Curated (pronto para uso).

Fonte: dwbi1.wordpress.com

ATENÇÃO

Cuidado com o Data Swamp! 🐊

1. **Data Swamp:** um Data Lake abandonado e sem organização
2. **Causa:** dados sem catalogação, governança ou descarte
3. **Resultado:** ninguém sabe o que existe, custo alto, valor zero
4. **Prevenção:** metadados, controle de acesso e catalogação
5. **LGPD:** dados pessoais precisam de ciclo e criptografia

💡 ANALOGIA

Um lago sem manutenção vira pântano: lodo, água suja e impossível de navegar. Invista em governança (o jardineiro do lago) para mantê-lo navegável e valioso!

RESUMO

Recapitulando a Aula

- ✓ Data Lake armazena qualquer tipo de dado em escala — bruto e flexível.
- ✓ DW e Data Lake se complementam; use ambos conforme a necessidade.
- ✓ Cuidado com o Data Swamp: governança, metadados e LGPD são essenciais.
- ✓ Na nuvem: AWS S3, Azure Blob Storage e Google Cloud Storage.